Reporte de Modelos — Predicción de Fuga de Clientes (Churn)

FinanceGuard — Proyecto Integrador Módulo 4 (Data Science)

Resumen ejecutivo

FinanceGuard, un banco digital con 10.000 clientes activos, enfrenta una tasa de abandono (churn) anual del 20%, con el objetivo de reducirla al 15% mediante un sistema predictivo que priorice las acciones del equipo de retención.

A lo largo de este proyecto se desarrollaron y compararon tres enfoques complementarios:

1. Un modelo **lineal e interpretable** (Regresión Logística) como línea base.
2. Modelos de **ensamble no lineales** (Random Forest, Gradient Boosting y Stacking), que mejoran sustancialmente la capacidad de detección.
3. Un análisis de **segmentación no supervisada** (clustering y reducción de dimensionalidad), que identifica perfiles de clientes con riesgos de churn muy distintos entre sí.

Adicionalmente, se ajustó el punto de corte de decisión del mejor modelo según una matriz de costos de negocio, lo que **duplicó el valor de negocio estimado** respecto de usar el umbral estándar de 0.5.

Conclusión principal: el churn de FinanceGuard no depende de una única variable dominante, sino de una combinación de antigüedad geográfica (clientes de Alemania), edad, nivel de actividad y número de productos contratados — con una relación marcadamente no lineal en esta última variable, razón por la cual los modelos de boosting superan de forma consistente al modelo lineal.

---

1. Contexto y objetivo del proyecto

Como Científico de Datos Junior, el rol en este proyecto fue desarrollar un modelo de Machine Learning completo que prediga qué clientes tienen mayor probabilidad de abandonar el banco, para que el equipo de retención pueda implementar estrategias personalizadas y reducir la tasa de churn del 20% al 15% objetivo.

El dataset de trabajo (`Churn_Modelling.csv`) contiene 10.000 clientes, sin valores nulos ni duplicados, con variables demográficas (edad, género, país, antigüedad) y financieras (saldo, número de productos, score crediticio, salario estimado, tarjeta de crédito, actividad). La variable objetivo (`Exited`) presenta un desbalanceo típico de este tipo de problemas: **~80% de clientes activos y ~20% de clientes que abandonan**.

---

2. Síntesis Avance 1 — Regresión Logística (modelo baseline)

Performance del modelo baseline

Métrica	Clase “Activo” (0)	Clase “Abandonó” (1)
Precision	0.82	0.59
Recall	0.97	0.19
F1-score	0.89	0.28

- **Accuracy general:** 0.81
- **ROC-AUC:** 0.775

Interpretabilidad y coeficientes más importantes

Convirtiendo los coeficientes del modelo a odds ratios, las variables con mayor efecto sobre la probabilidad de

churn fueron:

Variable	Odds ratio	Efecto
Geography_Germany	2.27	Ser cliente en Alemania **más que duplica** las chances de churn respecto de Francia
Age	2.09	A mayor edad (estandarizada), mayores chances de churn
IsActiveMember	0.36	Ser miembro activo **reduce** las chances de churn a menos de la mitad
Gender	0.59	Ser hombre reduce las chances de churn respecto de ser mujer
NumOfProducts	0.93	Efecto levemente negativo y cercano a neutro

Fortalezas y limitaciones identificadas

- **Fortaleza:** el modelo es completamente interpretable — cada coeficiente se traduce directamente en un odds ratio que el negocio puede entender y accionar.
- **Limitación principal:** el **Recall de la clase de interés es muy bajo (0.19)** — el modelo deja pasar más de 8 de cada 10 clientes que efectivamente abandonan. Esto es consistente con el desbalanceo de clases (80/20) y con la naturaleza lineal del modelo.
- **Hallazgo relevante:** el odds ratio de `NumOfProducts` (0.93) sugiere un efecto casi neutro, pero el análisis exploratorio del Avance 1 había detectado que los clientes con 3-4 productos tienen una tasa de churn muchísimo más alta que los de 1-2 productos. La Regresión Logística, al ser un modelo **lineal**, no puede capturar esta relación **no monótona** (el riesgo no crece ni decrece de forma constante con el número de productos, sino que se dispara en los extremos) — es la limitación más concreta del modelo baseline, y la motivación central para explorar modelos no lineales en el Avance 2.

---

3. Síntesis Avance 2 — Gradient Boosting y Stacking

Comparación de modelos

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC	PR-AUC	Valor de negocio*
CatBoost	0.809	0.521	**0.757**	0.617	0.869	**0.723**	**27.970**
Stacking (XGB+LGBM+CatBoost)	**0.865**	**0.718**	0.555	0.626	0.869	0.721	21.710
XGBoost (Optuna)	0.803	0.510	0.754	0.609	0.869	0.716	27.750
XGBoost (Grid Search)	0.802	0.509	0.745	0.605	0.867	0.717	27.380
XGBoost (base)	0.800	0.505	0.737	0.599	0.870	0.718	27.060
LightGBM	0.805	0.515	0.698	0.592	0.858	0.704	25.720
Random Forest	0.821	0.546	0.708	0.616	0.866	0.702	26.400

*Métrica de negocio simplificada (unidades relativas), penalizando Falsos Positivos y premiando Verdaderos Positivos.

Mejor modelo identificado

CatBoost es el modelo individual con mejor equilibrio para este problema de negocio: el mejor PR-AUC (0.723), el mejor Recall (0.757) y el mejor valor de negocio de todo el grupo, incluyendo al ensamble de Stacking. El **Stacking** logra la mejor Accuracy y Precision, pero a costa de un Recall notablemente menor (0.555) — su meta-learner (Regresión Logística regularizada) tiende a ser conservador, lo que reduce Falsos Positivos pero también detecta menos casos reales de churn.

Feature importance del mejor modelo

Tanto en Random Forest como en XGBoost, las variables más importantes para predecir el churn son consistentemente: `Age`, `NumOfProducts`, `IsActiveMember` y `Geography_Germany` — las mismas señales identificadas en el Avance 1, pero ahora capturadas de forma no lineal.

Ganancia en performance vs. el modelo baseline

Métrica	Regresión Logística (Avance 1)	CatBoost (Avance 2)	Mejora
ROC-AUC	0.775	0.869	+0.094
Recall (clase churn)	0.19	0.757	**+0.567**
Precision (clase churn)	0.59	0.521	-0.069

La ganancia más significativa es en **Recall**: el modelo de boosting detecta casi 4 veces más clientes en riesgo real que el modelo lineal, a un costo moderado en Precision. Para un problema de retención, donde no detectar a un cliente que se va representa una pérdida de negocio directa, este trade-off es claramente favorable.

---

4. Síntesis Avance 3 — Aprendizaje No Supervisado

Segmentos de clientes identificados

Con **K-Means (K=4)**, seleccionado combinando el método del codo y el coeficiente de silueta junto con el criterio de negocio de identificar entre 3 y 5 segmentos accionables, se identificaron los siguientes perfiles:

Cluster	Perfil	Tasa de churn	Clientes
0	Clientes de **Alemania**, saldo medio-alto (~\$119.700)	**32.4%**	2.509
1	Clientes de Francia, saldo alto (~\$122.900), pocos productos (1.21 en promedio)	16.4%	2.399
2	Clientes de España, saldo medio (~\$61.800)	16.7%	2.477
3	Clientes de Francia, saldo muy bajo (~\$6.300), más productos (1.82 en promedio)	15.9%	2.615

Insights de negocio por cluster

- El **Cluster 0 (clientes de Alemania)** tiene una tasa de churn **el doble** que el resto de los segmentos (32.4% vs. ~16% en los demás) — confirma cuantitativamente, a nivel de segmento completo, el patrón de riesgo geográfico ya detectado en los Avances 1 y 2, y lo convierte en un **segmento prioritario y claramente delimitado** para una campaña de retención focalizada.
- Los segmentos de menor riesgo (clusters 1, 2 y 3) muestran variaciones más sutiles entre sí, ligadas principalmente al país y al saldo, sin un segundo "cluster de alto riesgo" tan marcado como el 0.
- DBSCAN, aplicado como análisis complementario, identificó un 0.9% de clientes como "ruido" (outliers) — clientes con combinaciones de variables atípicas que no encajan claramente en ningún segmento denso, y que podrían requerir revisión manual individual en vez de una estrategia de segmento.

Features derivadas del clustering

Se generaron tres variables nuevas, disponibles para enriquecer futuros modelos supervisados: el **cluster asignado** (categórica), la **distancia de cada cliente al centroide de su propio cluster** (mide qué tan "típico" es un cliente dentro de su segmento) y un **flag de outlier según DBSCAN**.

---

5. Trade-offs de negocio y optimización del punto de corte (Extra Credit)

Con CatBoost como modelo elegido, se evaluó el impacto de ajustar el **threshold de decisión** según una matriz

de costos personalizada (beneficio de +100 por cliente retenido a tiempo, costo de -10 por contacto innecesario, costo de -150 por cliente perdido sin detectar — reflejando que perder un cliente es más costoso que una campaña de más).

Threshold	Valor de negocio estimado
0.50 (default)	13.120
0.09 (óptimo de negocio)	**26.690**

Ajustar el threshold de 0.5 a 0.09 **duplica el valor de negocio estimado** (+103%), reduciendo drásticamente los Falsos Negativos a costa de aceptar más Falsos Positivos — un trade-off directamente alineado con la estructura de costos real de un problema de retención, donde perder un cliente sin haber actuado es el error más caro.

---

6. Integración de aprendizaje supervisado y no supervisado

Los dos enfoques no compiten entre sí, sino que se complementan en distintos momentos de la estrategia de retención:

- El **modelo supervisado** (CatBoost, con threshold ajustado) responde la pregunta operativa del día a día: *"¿este cliente puntual tiene alta probabilidad de irse?"* — es la base para priorizar contactos individuales.
- La **segmentación no supervisada** responde una pregunta más estratégica: *"¿qué grupos de clientes con comportamientos similares existen, y cómo se comporta el churn en cada uno?"* — es la base para diseñar campañas y políticas diferenciadas por segmento (ej. una oferta específica para el Cluster 0 de Alemania).
- Las **features derivadas del clustering** (cluster, distancia al centroide, flag de outlier) pueden incorporarse como variables adicionales en una futura iteración de los modelos supervisados, aportando información sobre la "tipicidad" de cada cliente dentro de su segmento que los modelos originales no tenían.

---

7. Lecciones aprendidas

¿Cuándo usar modelos supervisados vs. no supervisados?

- Los modelos **supervisados** son la herramienta correcta cuando existe una variable objetivo clara (`Exited`) y el objetivo es **predecir o priorizar** casos individuales — por ejemplo, generar un score de riesgo por cliente para el equipo de retención.
- Los modelos **no supervisados** son la herramienta correcta cuando no hay (o no se quiere usar) una variable objetivo, y el objetivo es **describir y descubrir estructura** en los datos — identificar qué "tipos" de clientes existen, más allá de si finalmente abandonan o no. También son útiles como paso de **feature engineering** para enriquecer, después, un modelo supervisado.
- En este proyecto, ambos enfoques **confirmaron los mismos factores de riesgo** (geografía, edad, actividad, número de productos) desde ángulos distintos — la coincidencia entre un análisis supervisado y uno no supervisado, independientes entre sí, es una señal de robustez de esos hallazgos.

Consideraciones para futuros proyectos de churn

- El desbalanceo de clases (80/20) debe tenerse en cuenta desde el diseño del proyecto: elegir métricas apropiadas (PR-AUC, Recall) desde el principio, en vez de confiar en el accuracy.
- El punto de corte (threshold) de un modelo de clasificación es una **decisión de negocio**, no un detalle técnico — ajustarlo según costos reales puede aportar más valor que seguir optimizando el modelo en sí.
- Vale la pena revisar variables con relaciones **no monótonas** (como `NumOfProducts` en este proyecto) con especial atención, ya que los modelos lineales pueden subestimar completamente su importancia real.
- La segmentación no supervisada es más útil cuando se la analiza **en conjunto con la variable objetivo** (aunque no se haya usado para entrenar el clustering) — es lo que permitió pasar de "4 segmentos genéricos" a "un segmento de alto riesgo claramente identificado".

---

8. Recomendaciones estratégicas para FinanceGuard

1. **Priorizar una campaña de retención específica para clientes de Alemania**, dado que representan el segmento con mayor tasa de churn (32.4%, el doble que el resto).
2. **Usar el score de probabilidad de CatBoost, ajustado al threshold de negocio (0.09)**, para priorizar los contactos del equipo de retención, en lugar de una regla fija de 0.5.
3. **Investigar por qué los clientes con 3-4 productos contratados muestran mayor riesgo de churn** — contraintuitivamente, más productos no implica mayor fidelización en este banco; podría indicar sobreventa de productos que el cliente no valora o dificultades de gestión de múltiples productos a la vez.
4. **Diseñar acciones para aumentar la actividad de clientes inactivos** (`IsActiveMember`), ya que es la variable más "accionable" entre las de mayor peso predictivo (a diferencia de la edad o la geografía, que no se pueden modificar).
5. **Revisar periódicamente los costos de la matriz de negocio** (valor de retención, costo de contacto, costo de pérdida) junto con el equipo comercial, y re-optimizar el threshold cuando esos costos cambien.